ARQUITECTURA LAKEHOUSE • MEDALLION 2.0 • IA SOBERANA LOCAL

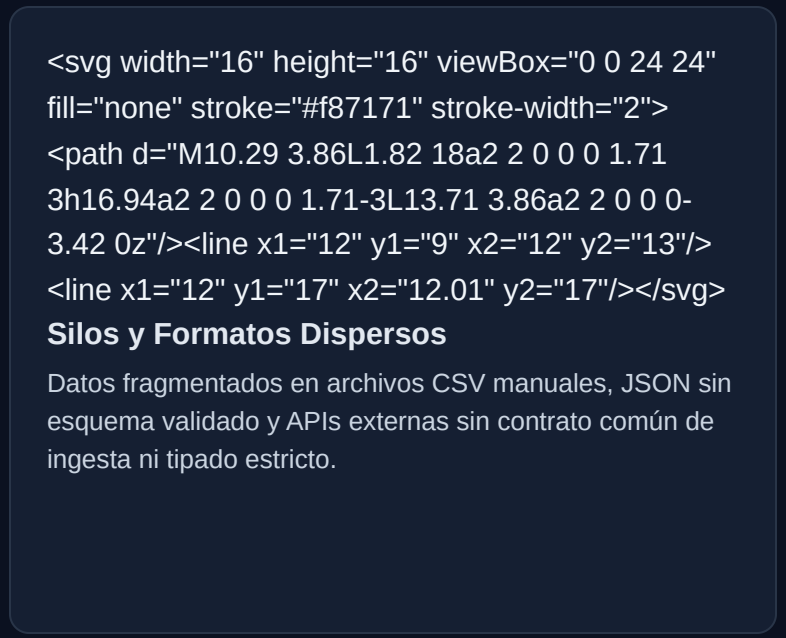
Plataforma Extensible de Datos y Analítica

Ingeniería de datos integral con MinIO, Apache Spark, aceleración analítica con DuckDB y Chatbot con LLM Soberano (Qwen 2.5) sin costes de API.

Almacenamiento
MinIO S3 Lakehouse
Procesamiento
Apache Spark 3.5
Motor Analítico
DuckDB + Parquet
Inteligencia Artificial
Qwen 2.5 (2B Local)

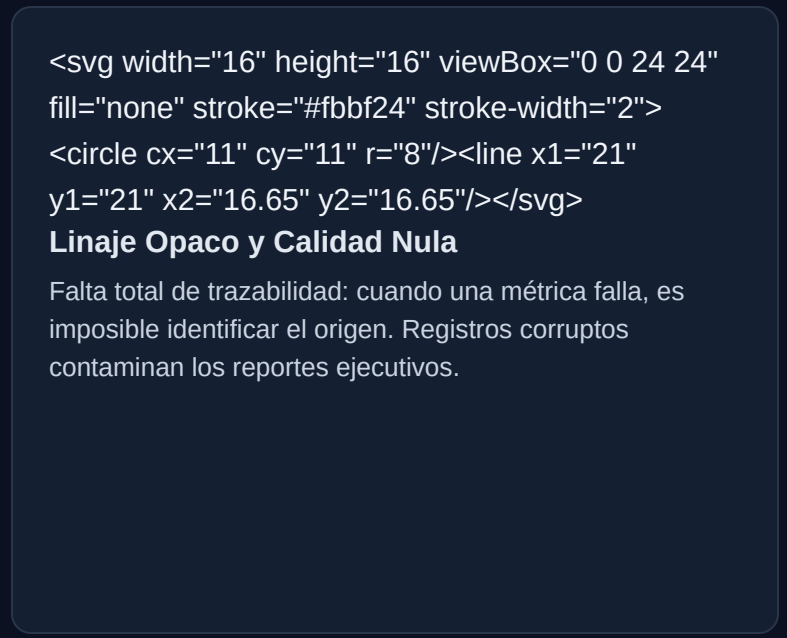
El Problema y Desafíos Actuales

¿Por qué las organizaciones no confían en sus datos ni aprovechan la IA analítica?



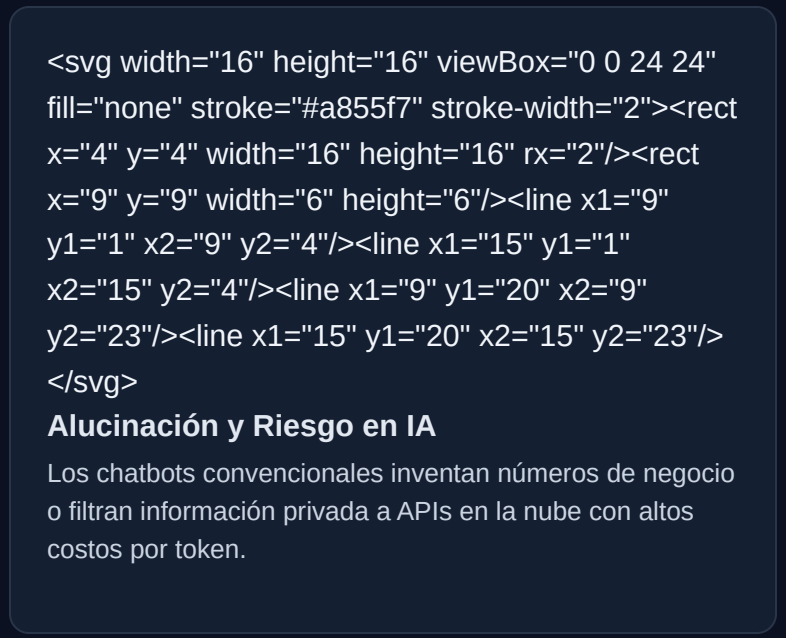
Silos y Formatos Dispersos

Datos fragmentados en archivos CSV manuales, JSON sin esquema validado y APIs externas sin contrato común de ingesta ni tipado estricto.



Linaje Opaco y Calidad Nula

Falta total de trazabilidad: cuando una métrica falla, es imposible identificar el origen. Registros corruptos contaminan los reportes ejecutivos.



Alucinación y Riesgo en IA

Los chatbots convencionales inventan números de negocio o filtran información privada a APIs en la nube con altos costos por token.

Propuesta de Valor y Principios de Diseño

Consistencia garantizada: Una única fuente de verdad (Single Source of Truth)

PRINCIPIO 1: ARQUITECTURA LAKEHOUSE MEDALLION

Tratamiento Secuencial por Madurez

- Flujo desacoplado en capas: **Landing**, **Bronze**, **Silver**, **Gold** y **Cuarentena**.
- **Procesamiento Idempotente:** Apache Spark asegura reprocesamiento sin duplicar filas.
- **Aislamiento Activo:** Datos corruptos no bloquean la ingesta de registros limpios.

PRINCIPIO 2: CONSUMO CONSISTENTE Y SOBERANO

Mismas Métricas para Dashboard y Chatbot

- **Doble Canal Unificado:** Streamlit (BI visual) y Chatbot IA consultan la misma capa Gold.
- **Cero Alucinaciones:** El chatbot traduce preguntas a sentencias SQL reales ejecutadas con DuckDB.
- **100% Soberanía y $0 Inferencia:** Modelo Qwen 2.5 local sin envíos a APIs externas.

Arquitectura End-to-End

De la ingesta heterogénea al valor analítico accionable



Arquitectura Medallion al Detalle

Trazabilidad y elevación progresiva de la calidad del dato

FLUJO DE PROCESAMIENTO SECUENCIAL Y ELEVACIÓN DE CALIDAD



Calidad Progresiva: La limpieza y validación ocurre en la transición **Bronze → Silver**. Los registros corruptos se desvían a **Cuarentena** antes de entrar a Silver, protegiendo las capas analíticas

Capa Gold: Modelos de Negocio

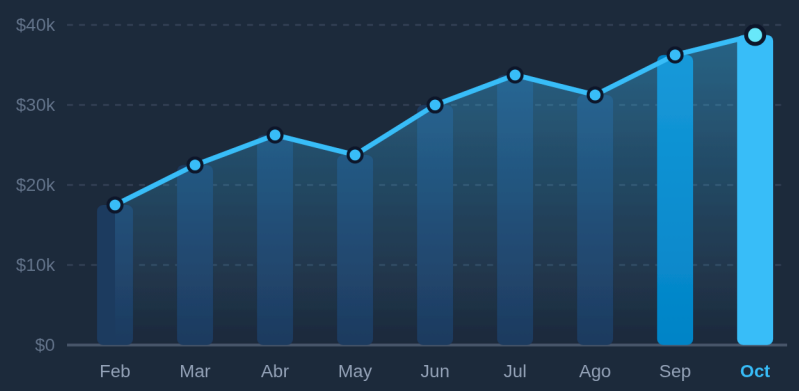
Data Marts optimizados para consumo inmediato en Dashboards y Chatbot

daily_sales • Evolución de Ingresos y Pedidos

DuckDB Gold

Ingresos Totales:
$1,842,500 +14.2%

Pedidos Completados:
12,480 Ticket: $147.6



customer_360 • RFM



- Champions / VIP 42%
- Recurrentes 28%
- En Riesgo 19%
- Inactivos 11%

LTV Promedio: $1,420 USD

product_performance

Top Categorías por Margen:

1. Hardware & Servidores
2. Licencias Cloud & SaaS
3. Periféricos & Redes

BENCHMARK CONSULTA

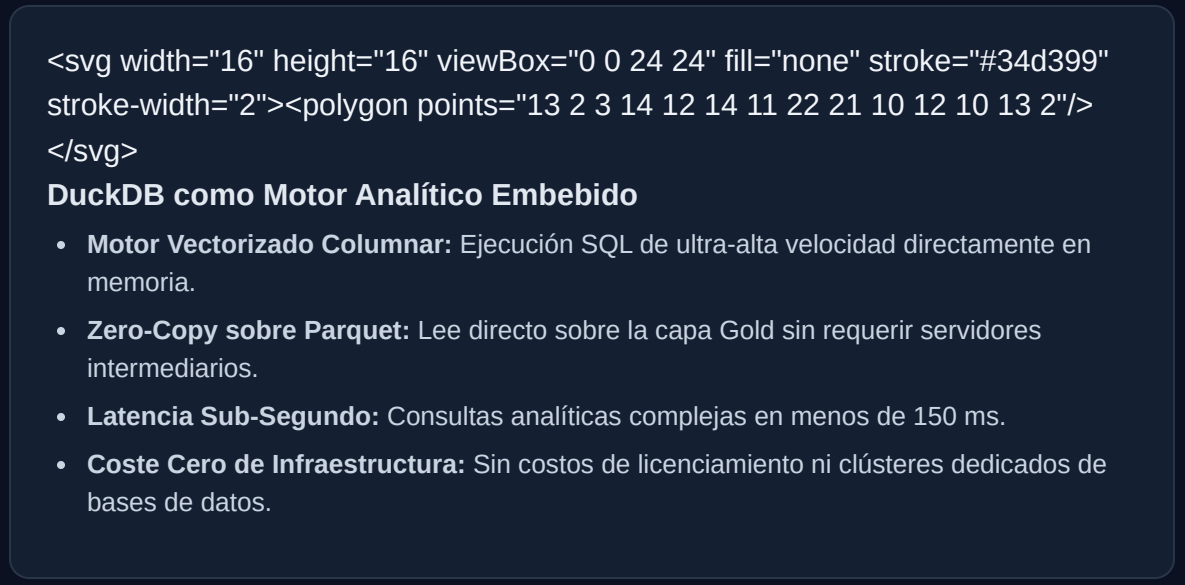
Lectura 10M filas con DuckDB:

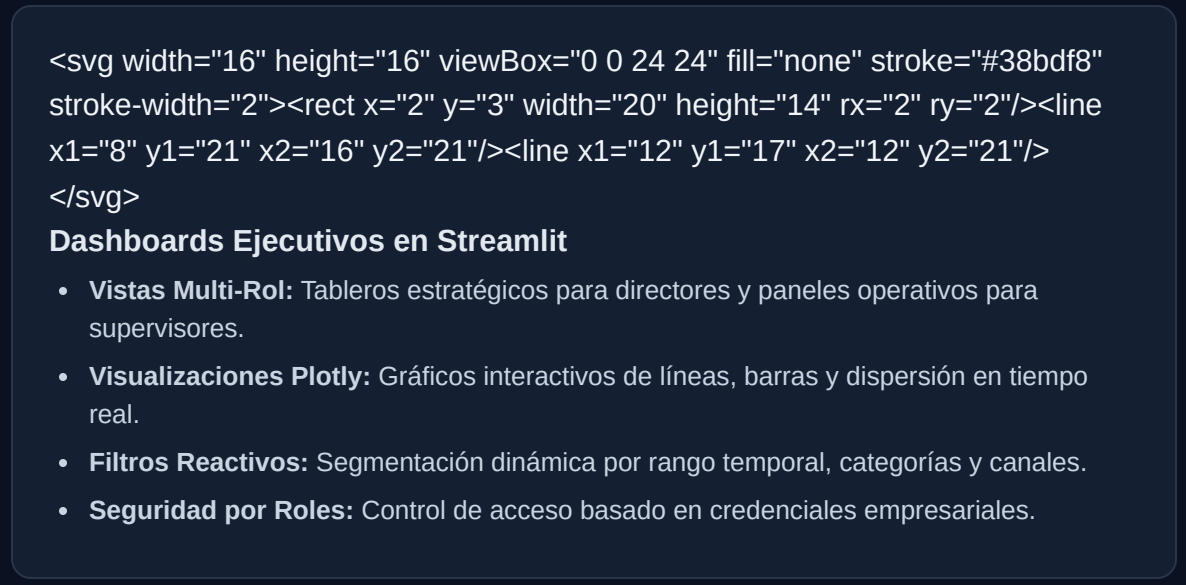
PostgreSQL Tradicional:
4,850 ms (4.8 seg)

DuckDB Embebido (Gold):
118 ms (41x más rápido)

Visualización e Hiper-Rendimiento

DuckDB + Streamlit: Analítica interactiva en milisegundos





Chatbot Analítico Inteligente

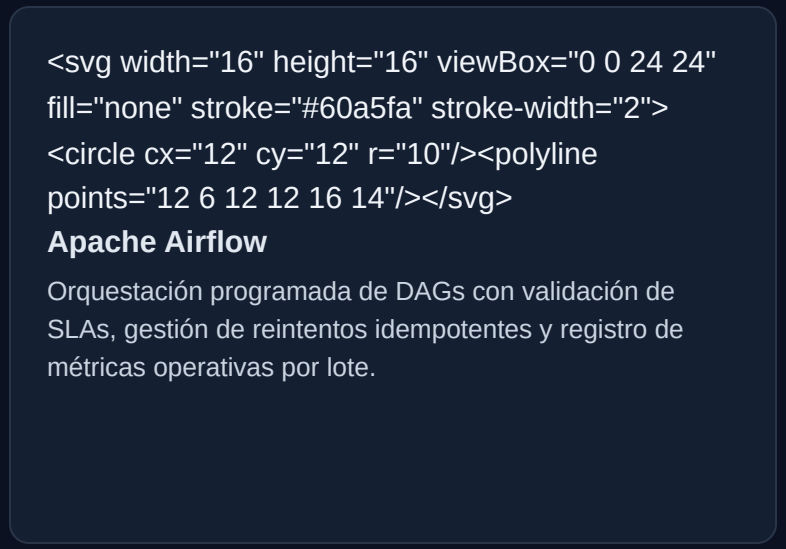
NL-to-SQL Soberano: Modelo Qwen 2.5 (2B) sin dependencias externas

ARQUITECTURA DE CONSULTA EN LENGUAJE NATURAL A SQL (NL-TO-SQL)



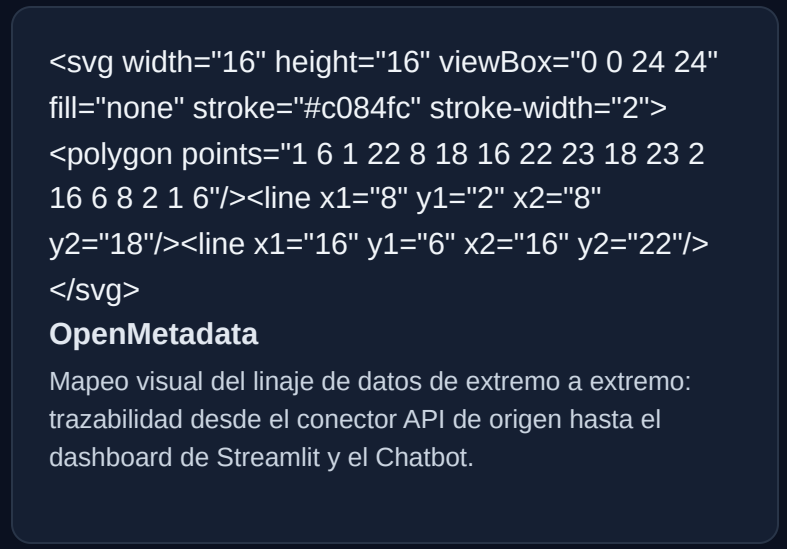
Gobernanza, Linaje y Operación Continua

Control total de extremo a extremo: calidad, contratos y observabilidad



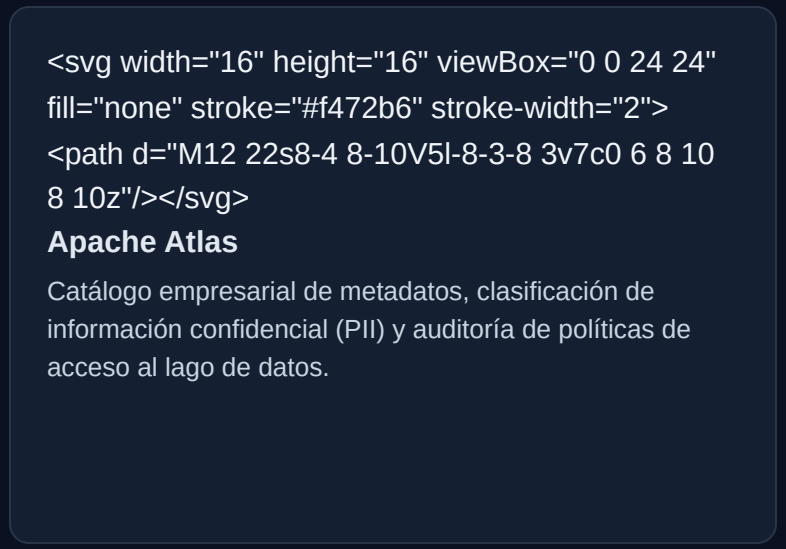
Apache Airflow

Orquestación programada de DAGs con validación de SLAs, gestión de reintentos idempotentes y registro de métricas operativas por lote.



OpenMetadata

Mapeo visual del linaje de datos de extremo a extremo: trazabilidad desde el conector API de origen hasta el dashboard de Streamlit y el Chatbot.



Apache Atlas

Catálogo empresarial de metadatos, clasificación de información confidencial (PII) y auditoría de políticas de acceso al lago de datos.

Entrega Técnica y Pruebas Rigurosas

Metodología Mock-First y Suite Automatizada con 82 Pruebas

DESARROLLO DESACOPLADO

Metodología Mock-First

Generación de datos sintéticos controlados para habilitar el avance en paralelo de los 7 roles sin cuellos de botella de integración.

COBERTURA FUNCIONAL

Matriz P01 a P12

Pruebas formales de contratos de esquema, idempotencia Spark, aislamiento estricto en Cuarentena y seguridad AST en SQLGuard.

VELOCIDAD CI/CD

82 Tests en < 4 Segundos

Suite automatizada completa ejecutada con Pytest en hardware convencional, garantizando calidad continua y cero regresiones.

Impacto y Ventajas Competitivas

Comparativa: Arquitectura Tradicional vs Plataforma Extensible de Datos

Dimensión	Enfoque Tradicional en la Nube	Nuestra Plataforma Integrada
Costos de Inferencia IA	Facturación recurrente por token (OpenAI/Anthropic)	$0 en inferencia: Modelo 2B local soberano
Confiabilidad de Datos	Métricas discordantes entre BI y chatbots	Mismo motor (DuckDB) para Dashboard y Bot
Latencia de Consulta	Varios segundos/minutos en Data Warehouses pesados	Sub-segundo (< 150 ms) con DuckDB + Parquet
Privacidad y Seguridad	Datos sensibles viajan a APIs de terceros	Soberanía total on-premise o nube privada
Gobernanza y Linaje	Trazabilidad manual o nula ante fallos	Linaje automatizado con OpenMetadata y Atlas

Conclusión y Roadmap Futuro

Democratización analítica con rigor técnico, privacidad y gobernanza

Logros Consolidados en v2.0

- Pipeline Lakehouse Medallion con zona activa de Cuarentena.
- Capa de servicio analítica de alta velocidad con DuckDB embebido.
- Chatbot NL-to-SQL con IA local soberana, catálogo de errores y cero fallbacks.
- 100% verificado: 82 pruebas automáticas y documentación viva.

Próximos Pasos en el Roadmap

- **Streaming en Tiempo Real:** Ingesta continua con Apache Kafka y Spark Streaming.
- **Detección de Data Drift:** Alertas automáticas de desviación de calidad en esquemas.
- **Análisis Predictivo:** Inferencia de series temporales integrada en el Chatbot.

PIPELINE ANALÍTICA • OCTUBRE 2026

¡Muchas Gracias!

Espacio Abierto para Preguntas y Discusión Técnica

Equipo del Proyecto: Ingeniería de Datos y Analítica (7 Integrantes)
Repositorio: `Pipeline-analitica` (Branch: `develop`)
Documentación Técnica: `documentation/arquitectura-medallion.md`