ARQUITECTURA LAKEHOUSE • MEDALLION 2.0 • IA SOBERANA LOCAL

Plataforma Extensible de Datos y Analítica

Ingeniería de datos integral con MinIO, Apache Spark, aceleración analítica con DuckDB y Chatbot con LLM Soberano (Qwen 2.5) sin costes de API.

ALMACENAMIENTO	PROCESAMIENTO	MOTOR ANALÍTICO	INTELIGENCIA ARTIFICIAL
MinIO S3 Lakehouse	Apache Spark 3.5	DuckDB + Parquet	Qwen 2.5 (2B Local)

El Problema y Desafíos Actuales

¿Por qué las organizaciones no confían en sus datos ni aprovechan la IA analítica?

Silos y Formatos Dispersos

Datos fragmentados en archivos CSV manuales, JSON sin esquema validado y APIs externas sin contrato común de ingesta ni tipado estricto.

Linaje Opaco y Calidad Nula

Falta total de trazabilidad: cuando una métrica falla, es imposible identificar el origen. Registros corruptos contaminan los reportes ejecutivos.

Alucinación y Riesgo en IA

Los chatbots convencionales inventan números de negocio o filtran información privada a APIs en la nube con altos costos por token.

Propuesta de Valor y Principios de Diseño

Consistencia garantizada: Una única fuente de verdad (Single Source of Truth)

PRINCIPIO 1: ARQUITECTURA LAKEHOUSE MEDALLION

Tratamiento Secuencial por Madurez

- Flujo desacoplado en capas: **Landing**, **Bronze**, **Silver**, **Gold** y **Cuarentena**.
- **Procesamiento Idempotente:** Apache Spark asegura reprocesamiento sin duplicar filas.
- **Aislamiento Activo:** Datos corruptos no bloquean la ingesta de registros limpios.

PRINCIPIO 2: CONSUMO CONSISTENTE Y SOBERANO

Mismas Métricas para Dashboard y Chatbot

- **Doble Canal Unificado:** Streamlit (BI visual) y Chatbot IA consultan la misma capa Gold.
- **Cero Alucinaciones:** El chatbot traduce preguntas a sentencias SQL reales ejecutadas con DuckDB.
- **100% Soberanía y $0 Inferencia:** Modelo Qwen 2.5 local sin envíos a APIs externas.

Arquitectura End-to-End

De la ingesta heterogénea al valor analítico accionable



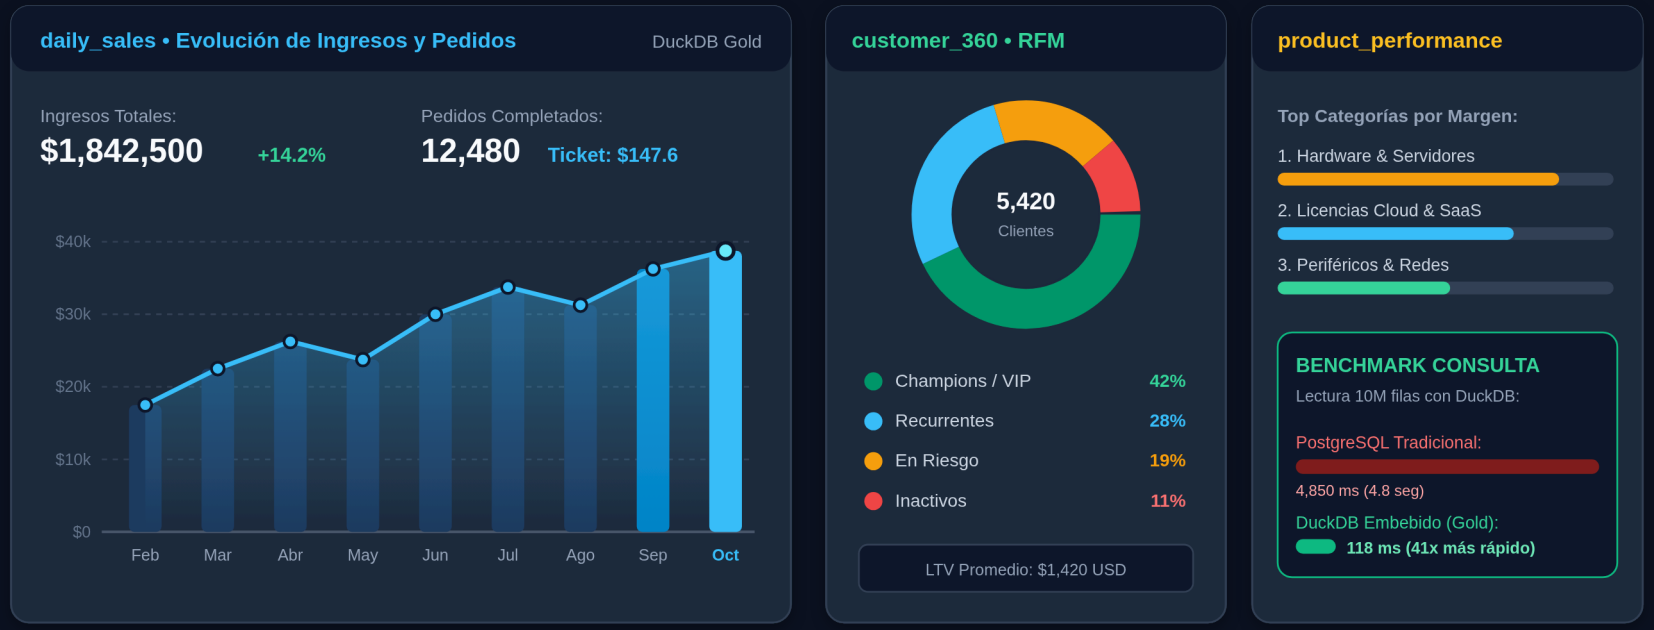
Arquitectura Medallion al Detalle

Trazabilidad y elevación progresiva de la calidad del dato



Capa Gold: Modelos de Negocio

Data Marts optimizados para consumo inmediato en Dashboards y Chatbot



Visualización e Hiper-Rendimiento

DuckDB + Streamlit: Analítica interactiva en milisegundos

DuckDB como Motor Analítico Embebido

- **Motor Vectorizado Columnar:** Ejecución SQL de ultra-alta velocidad directamente en memoria.
- **Zero-Copy sobre Parquet:** Lee directo sobre la capa Gold sin requerir servidores intermediarios.
- **Latencia Sub-Segundo:** Consultas analíticas complejas en menos de 150 ms.
- **Coste Cero de Infraestructura:** Sin costos de licenciamiento ni clústeres dedicados de bases de datos.

Dashboards Ejecutivos en Streamlit

- **Vistas Multi-Rol:** Tableros estratégicos para directores y paneles operativos para supervisores.
- **Visualizaciones Plotly:** Gráficos interactivos de líneas, barras y dispersión en tiempo real.
- **Filtros Reactivos:** Segmentación dinámica por rango temporal, categorías y canales.
- **Seguridad por Roles:** Control de acceso basado en credenciales empresariales.

Chatbot Analítico Inteligente

NL-to-SQL Soberano: Modelo Qwen 2.5 (2B) sin dependencias externas



Gobernanza, Linaje y Operación Continua

Control total de extremo a extremo: calidad, contratos y observabilidad

Apache Airflow

Orquestación programada de DAGs con validación de SLAs, gestión de reintentos idempotentes y registro de métricas operativas por lote.

OpenMetadata

Mapeo visual del linaje de datos de extremo a extremo: trazabilidad desde el conector API de origen hasta el dashboard de Streamlit y el Chatbot.

Apache Atlas

Catálogo empresarial de metadatos, clasificación de información confidencial (PII) y auditoría de políticas de acceso al lago de datos.

Entrega Técnica y Pruebas Rigurosas

Metodología Mock-First y Suite Automatizada con 82 Pruebas

DESARROLLO DESACOPLADO

Metodología Mock-First

Generación de datos sintéticos controlados para habilitar el avance en paralelo de los 7 roles sin cuellos de botella de integración.

COBERTURA FUNCIONAL

Matriz P01 a P12

Pruebas formales de contratos de esquema, idempotencia Spark, aislamiento estricto en Cuarentena y seguridad AST en SQLGuard.

VELOCIDAD CI/CD

82 Tests en < 4 Segundos

Suite automatizada completa ejecutada con Pytest en hardware convencional, garantizando calidad continua y cero regresiones.

Impacto y Ventajas Competitivas

Comparativa: Arquitectura Tradicional vs Plataforma Extensible de Datos

Dimensión	Enfoque Tradicional en la Nube	Nuestra Plataforma Integrada
Costos de Inferencia IA	Facturación recurrente por token (OpenAI/Anthropic)	**$0 en inferencia:** Modelo 2B local soberano
Confiabilidad de Datos	Métricas discordantes entre BI y chatbots	**Mismo motor (DuckDB)** para Dashboard y Bot
Latencia de Consulta	Varios segundos/minutos en Data Warehouses pesados	**Sub-segundo (< 150 ms)** con DuckDB + Parquet
Privacidad y Seguridad	Datos sensibles viajan a APIs de terceros	**Soberanía total on-premise** o nube privada
Gobernanza y Linaje	Trazabilidad manual o nula ante fallos	**Linaje automatizado** con OpenMetadata y Atlas

Conclusión y Roadmap Futuro

Democratización analítica con rigor técnico, privacidad y gobernanza

Logros Consolidados en v2.0

- Pipeline Lakehouse Medallion con zona activa de Cuarentena.
- Capa de servicio analítica de alta velocidad con DuckDB embebido.
- Chatbot NL-to-SQL con IA local soberana, catálogo de errores y cero fallbacks.
- 100% verificado: 82 pruebas automáticas y documentación viva.

Próximos Pasos en el Roadmap

- **Streaming en Tiempo Real:** Ingesta continua con Apache Kafka y Spark Streaming.
- **Detección de Data Drift:** Alertas automáticas de desviación de calidad en esquemas.
- **Análisis Predictivo:** Inferencia de series temporales integrada en el Chatbot.

PIPELINE ANALÍTICA • OCTUBRE 2026

¡Muchas Gracias!

Espacio Abierto para Preguntas y Discusión Técnica

Equipo del Proyecto: Ingeniería de Datos y Analítica (7 Integrantes)

Repositorio: `Pipeline-analitica` (Branch: `develop`)

Documentación Técnica: `documentation/arquitectura-medallion.md`